

基因集富集分析 (GSEA)

分析说明


基因集富集分析(GSEA, Gene Set Enrichment Analysis)是一种对基因集进行富集分析的方法。

其使用预定义的基因集（通常来自功能注释或先前实验的结果），将基因按照在两类样本中的差异表达程度排序，然后检验预先设定的基因集合是否在这个排序表的顶端或者底端富集。基因集富集分析检测基因集合而不是单个基因的表达变化，因此可以包含这些细微的表达变化，预期得到更为理想的结果。

GSEA 分析有三个特点：

- 1, 分析的基因集合而不是单个基因；
- 2, 将基因与预定义的基因集进行比较；
- 3, 富集分析。

分析思路：



GSEA 的输入是一个基因表达量矩阵，其中的样本分成了 A 和 B 两组，首先对所有基因进行排序（foldchange），用来表示基因在两组间表达量的变化趋势。排序之后的基因列表其顶部可以看做是上调的差异基因，其底部是下调的差异基因。

GSEA 分析的是一个基因集下的所有基因是否在这个排序列表的顶部或者底部富集,如果在顶部富集,我们可以说,从总体上看,该基因集是上调趋势,反之,如果在底部富集,则是下调趋势。

比较常规富集分析:

一般的差异富集分析(GO 和 Pathway)往往侧重于比较两组间的基因表达差异,集中关注少数几个显著上调或下调的基因,这容易遗漏部分差异表达不显著却有重要生物学意义的基因,忽略一些基因的生物特性、基因调控网络之间的关系及基因功能和意义等有价值的信息。而 GSEA 不需要指定明确的差异基因阈值,算法会根据实际数据的整体趋势,为研究者们提供了一种合理地解决目前芯片分析瓶颈问题的方法,即使在没有先验经验存在的情况下也能在表达谱整体层次上对数千条基因进行分析,从而从数理统计上把表达谱芯片数据与生物学意义很好地衔接起来,使得研究者们能够更轻松、更合理地解读芯片或测序结果。

默认数据库:

MsigDB (<http://software.broadinstitute.org/gsea/msigdb>) 是专门针对 GSEA 这种方法而建立的数据库,与 KEGG\GO 类似。

使用软件: GSEA

GSEA 官网: <http://www.gsea-msigdb.org/gsea/index.jsp>

结果解读

注：本部分相关数据图片均为示例结果，非实际项目结果；老师可基于相关说明对本项目实际数据信息进行查阅。

为便于结果查阅，每组 GSEA 分析均给出了一个汇总的 html 页面（文件名：**index.html**）。

对于富集结果，根据上调还是下调分成了两个部分，对应两个分组，示例如下：

Enrichment in phenotype: WT (17 samples)

- 143 / 308 gene sets had enrichment in phenotype **WT**
- 14 gene set(s) are significant at nominal pvalue < 5%
- 5 gene set(s) are significant at FDR < 25%
- Detailed [enrichment results in html](#) format
- Detailed [enrichment results in excel](#) format (tab delimited text)

Enrichment in phenotype: MUT (33 samples)

- 165 / 308 gene sets had enrichment in phenotype **MUT**
- 25 gene set(s) are significant at nominal pvalue < 5%
- 2 gene set(s) are significant at FDR < 25%
- Detailed [enrichment results in html](#) format
- Detailed [enrichment results in excel](#) format (tab delimited text)

在每个组别下富集到的基因集，从总体上看，其表达量在该组中高表达。点击 enrichment results in html，可以在网页查看富集的结果，示例如下

Table: Gene sets enriched in phenotype WT (17 samples) [\[plain text format\]](#)

	GS	GS DESC	SIZE	ES	NES	NOM p-val	FDR q-val	FWER p-val
1	hsp27Pathway	Details...	15	0.78	2.18	0.000	0.003	0.004
2	p53hypoxiaPathway	Details...	20	0.68	2.08	0.000	0.009	0.013
3	p53Pathway	Details...	16	0.75	2.06	0.000	0.009	0.018
4	P53_UP	Details...	40	0.60	1.88	0.000	0.065	0.195
5	radiation_sensitivity	Details...	26	0.57	1.83	0.002	0.088	0.296

其中：GS 为基因集的名字，通常为该基因集所富集到的通路信息；SIZE 代表该基因集下的基因总数；ES 代表富集分值（Enrichment score）；NES 代表标准化后的富集分值；NOM p-val 代表 pvalue，表示富集结果的可信；FDR q-val 代表 qvalue，是多重假设检验校正后的 p 值。注意：GSEA 采用 pvalue < 5%, qvalue < 25% 对结果进行过滤。

点击 GS DESC 可以跳转到每个基因集详细结果页面，示例如下

Table: GSEA Results Summary

Dataset	P53_collapsed_symbols.P53.cls#MUT_versus_WT
Phenotype	P53.cls#MUT_versus_WT
Upregulated in class	MUT
GeneSet	CHRX11
Enrichment Score (ES)	0.5483351
Normalized Enrichment Score (NES)	1.7051458
Nominal p-value	0.016363636
FDR q-value	0.9492177
FWER p-Value	0.754


https://blog.csdn.net/weixin_43589473

首先是一个汇总的结果，Upregulated in class 说明该基因集在 MUT 这组中高表达，其他信息之前介绍的一样，除此之外，还有一个详细的表格，示例如下

	PROBE	DESCRIPTION (from dataset)	GENE SYMBOL	GENE_TITLE	RANK IN GENE LIST	RANK METRIC SCORE	RUNNING ES	CORE ENRICHMENT
1	RP2	na			1	0.559	0.0585	Yes
2	TFE3	na			52	0.383	0.0937	Yes
3	GPKOW	na			130	0.339	0.1215	Yes
4	PLP2	na			146	0.331	0.1547	Yes
5	HDAC6	na			247	0.300	0.1762	Yes
6	APEX2	na			282	0.294	0.2035	Yes
7	UBQLN2	na			330	0.282	0.2284	Yes
8	PHF8	na			349	0.276	0.2556	Yes
9	WDR45	na			396	0.266	0.2788	Yes
10	SSX2	na			497	0.250	0.2950	Yes
11	DDX3X	na			531	0.245	0.3174	Yes

对于该基因集下的每个基因给出了详细的统计信息，RANK IN GENE LIST 代表该基因在排序号的列表中的位置，RANK METRIC SCORE 代表该基因排序量的值，比如 foldchange 值，RUNNING ES 代表累计的 Enrichment score, CORE ENRICHMENT 代表是否属于核心基因，即对该基因集的 Enrichment score 做出了主要贡献的基因。

这个表格中的数据对应下面这张图



分成 3 个部分，第一部分为基因 Enrichment Score 的折线图，横轴为该基因下的每个基因，纵轴为对应的 Running ES，在折线图中有个峰值，该峰值就是这个基因集的 Enrichment score，峰值之前的基因就是该基因集下的核心基因。第二部分为 hit，用线条标记位于该基因集下的基因，第三部分为所有基因的 rank 值分布图，默认采用 Signal2Noise 算法，对应了纵轴的标题。

从该图中可以看出，这个基因集是在 MUT 这一组高表达的，下面是一个在另一组组中高表达的示例



凌恩生物

Frequency	Number of Responses
Daily	18
Several times a week	12
Once a week	8
Several times a month	5
Once a month	3
Less than once a month	2
Never	1



这张热图展示的是位于该基因集下的基因在所有样本中表达量的分布,其中每一列代表一个样本。每一行代表一个基因,基因表达量从低到高,颜色从蓝色过渡到红色。

在总的 html 页面中,还给出了如下信息

Dataset details

- The dataset has 10100 features (genes)
- No probe set => gene symbol collapsing was requested, so all 10100 features were used

Gene set details


- Gene set size filters (min=15, max=500) resulted in filtering out 158 / 326 gene sets
- The remaining 168 gene sets were used in the analysis
- List of [gene sets used and their sizes](#) (restricted to features in the specified dataset)


Gene markers for the MUT versus WT comparison

- The dataset has 10100 features (genes)
- # of markers for phenotype **MUT**: 4393 (43.5%) with correlation area 40.2%
- # of markers for phenotype **WT**: 5707 (56.5%) with correlation area 59.8%
- Detailed [rank ordered gene list](#) for all features in the dataset
- [Heat map and gene list correlation](#) profile for all features in the dataset
- [Buttelfly plot](#) of significant genes

Dataset details 给出了基因总数, Gene Set details 给出了基因集的信息, 注意软件默认根据基因集包含的基因个数是先对基因集进行过滤, 最小 15 个, 最大 500 个基因, 过滤掉了 158 个基因集, 剩余的 168 个基因集用于分析。

Gene markers 给出了排序之后的基因列表和对应的统计量 rank ordered gene list, 根据排序的统计量, 将基因分成了两部分, 对应在每一组中高表达。heatmap and gene list 包含了所有基因表达量的热图和排序值的分布图, 示意如下





热图由于基因太多，截取了部分，排序值的分布图其实就是每个基因集的 Enrichment plot

中的第三部分。更多的细节请查阅[官方文档](#)。



凌恩生物
— BIOZERON —